


선형 회귀

Multiple Linear Regression

다중선형회귀(Multiple Linear Regression)

- 다중선형회귀 란?

- 수치형 설명변수 X와 연속형 숫자로 이뤄진 종속변수 Y간의 관계를 선형으로 가정하고 이를 가장 잘 표현할 수 있는 회귀계수를 데이터로부터 추정하는 모델
- (예시) 1개의 설명변수(주택 크기:x1)와 연속형 종속변수(주택 가격:y)의 관계를 나타내는 지서의 차나 모델



다중선형회귀(Multiple Linear Regression)

- 다중선형회귀 모델 방정식

- N개의 데이터, K개의 설명변수($x_{11}, \dots, x_{nk}$), K개의 회귀계수($\beta_0, \dots, \beta_k$)

$$\begin{bmatrix} y_1 \\ y_2 \\ \dots \\ y_n \end{bmatrix} = \begin{bmatrix} 1 & x_{11} & \dots & x_{1k} \\ 1 & x_{21} & \dots & x_{2k} \\ \dots & \dots & & \dots \\ 1 & x_{n1} & \dots & x_{nk} \end{bmatrix} \begin{bmatrix} \beta_0 \\ \beta_1 \\ \dots \\ \beta_k \end{bmatrix} + \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \dots \\ \varepsilon_n \end{bmatrix}$$

$$\vec{y} = X \vec{\beta} + \vec{\varepsilon}, \quad \vec{\varepsilon} \sim N(E(\vec{\varepsilon}), V(\vec{\varepsilon}))$$

$$E(\vec{\varepsilon}) = \begin{bmatrix} 0 \\ 0 \\ \dots \\ 0 \end{bmatrix}, \quad V(\vec{\varepsilon}) = \sigma^2 I$$

다중선형회귀(Multiple Linear Regression)

- 회귀 계수 결정법 : Direct Solution




- 선형회귀의 계수들은 실제값(Y)과 모델 예측값(Y')의 차이, 오차제곱합(error sum of squares)을 최소로 하는 값을 회귀 계수로 선정
- 최적의 계수들은 회귀 계수에 대해 미분한 식을 0으로 놓고 풀면 **명시적인 해**를 구할 수 있음. 즉, X와 Y데이터 만으로 회귀 계수를 구할 수 있음

$$\vec{\beta} = (X^T X)^{-1} X^T \vec{y}$$

다중선형회귀(Multiple Linear Regression)

회귀 계수 결정법: Numerical Search

- 경사하강법(gradient descent) 같은 반복적인 방식으로 선형회귀 계수를 구할 수 있음
- 경사하강법이란 어떤 함수 값(목적 함수, 비용 함수, 에러 값)을 최소화하기 위해 임의의 시작점을 잡은 후 해당 지점에서의 그래디언트(경사)를 구하고, 그래디언트의 반대 방향으로 조금씩 이동하는 과정을 여러번 반복하는 것



다중선형회귀(Multiple Linear Regression)

■ Numerical Search

■ 경사하강법의 종류

■ Batch Gradient Descent (GD)


- 파라미터를 업데이트 할 때마다 모든 학습 데이터를 사용하여 cost function 의 gradient 를 계산
- Vanilla Gradient Descent 라 불림
- 매우 낮은 학습 효율을 보일 수 있음

■ Stochastic Gradient Descent (SGD)

- 파라미터를 업데이트 할 때, 무작위로 샘플링된 학습 데이터를 하나씩만 이용하여 cost function의 gradient를 계산
- 모델을 자주 업데이트 하며, 성능 개선 정도를 빠르게 확인 가능
- Local minima에 빠질 가능성을 줄일 수 있음
- 최소 cost에 수렴했는지의 판단이 상대적으로 어려움

■ Mini Batch Gradient Descent


- 파라미터를 업데이트 할때마다 일정량의 일부 데이터를 무작위로 뽑아 cost function의 gradient 를 계산
- Batch Gradient Descent와 Stochastic Gradient Descent 개념의 혼합
- SGD의 노이즈를 줄이면서, GD의 전체 배치보다 효율적
- 널리 사용되는 기법



정규화

■ 정규화(regularization)란?

- 회귀계수가 가질 수 있는 값에 제약조건을 부여하여 미래 데이터에 대한 오차 기대
- 미래데이터에 대한 오차의 기대 값은 모델의 **Bias**와 **variance**로 분해 가능.
- 정규화는 variance를 감소시켜 일반화 성능을 높이는 기법
 - 단, 이 과정에서 bias가 증가할 수 있음
- 왼쪽 그림은 학습데이터를 정말 잘 맞추고 있지만, 미래 데이터가 조금만 바뀌어도 예측 값이 들쭉날쭉할 수 있음
- 우측 그림은 가장 강한 수준의 정규화를 수행한 결과로 학습데이터에 대한 설명력을 다소 포기하는 대신 미래 데이터 변화에 상대적으로 안정적인 결과를 나타냄



정규화의 결과를 직관적으로 나타낸 그림

Bias-Variance Decomposition

■ Bias-Variance Decomposition란?

- 일반화(generalization) 성능을 높이는 정규화(Regularization), 앙상블(ensemble) 기법의 이론적 배경
- 학습에 쓰지 않은 미래데이터에 대한 오차의 기대값을 모델의 Bias와 Variance로 분해하자는 내용

■ Bias-Variance의 직관적인 이해

- 첫번째 그림을 보면 예측값(파란색 엑스포)의 평균이 과녁(Truth)과 멀리 떨어져 있어 Bias가 크고, 예측 값들이 서로 멀리 떨어져 있어 Variance 또한 큼
- 네번째 그림의 경우 Bias, Variance 모두 작음. 제일 이상적임
- 부스팅(Boosting)은 Bias 를 줄여 성능을 높이고. 라쏘회귀(Lasso regression)는 Variance를 줄여 성능을 높이는

